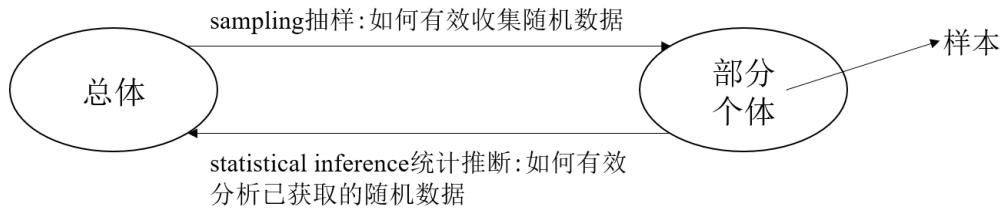


第9章 统计的基本概念

到 19 世纪末 20 世纪初, 随着近代数学和概率论的发展, 诞生了统计学.

统计学: 以概率论为基础, 研究如何有效收集研究对象的随机数据, 以及如何运用所获得的数据揭示统计规律的一门学科. 统计学的研究内容具体包括: 抽样、参数估计、假设检验等.



9.1 总体 (population) 与样本 (sample)

‘总体’是研究问题所涉及的对象全体; 总体中每个元素称为‘个体’. 总体分为有限或无限总体. 例如: 全国人民的收入是总体, 一个人的收入是个体.

在研究总体时, 通常关心总体的某项或某些数量指标, 总体中的每个个体是随机试验的一个观察值, 即随机变量 X 的值. 对总体的研究可转化为对随机变量 X 的分布或数字特征的研究, 后面总体与随机变量 X 的分布不再区分, 简称总体 X .

总体: 研究对象的全体 \Rightarrow 数据 \Rightarrow 随机变量 (分布未知).

样本: 从总体中随机抽取一些个体, 一般表示为 X_1, X_2, \dots, X_n , 称 X_1, X_2, \dots, X_n 为取自总体 X 的随机样本, 其样本容量为 n .

抽样: 抽取样本的过程.

样本值: 观察样本得到的数值, 例如: $X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$ 为样本观察值或样本值.

样本的二重性: i) 就一次具体观察而言, 样本值是确定的数; ii) 不同的抽样下, 样本值会发生变化, 可看作随机变量.

定义 9.1 (简单随机样本) 称样本 X_1, X_2, \dots, X_n 是总体 X 的简单随机样本, 简称样本, 是指样本满足: 1) 代表性, 即 X_i 与 X 同分布; 2) 独立性, 即 X_1, X_2, \dots, X_n 之间相互独立.

本书后面所考虑的样本均为简单随机样本.

设总体 X 的联合分布函数为 $F(x)$, 则 X_1, X_2, \dots, X_n 的联合分布函数为

$$F(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i);$$

若总体 X 的概率密度为 $f(x)$, 则样本 X_1, X_2, \dots, X_n 的联合概率密度为

$$f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i).$$

若总体 X 的分布列 $\Pr(X = x_i)$, 则样本 X_1, X_2, \dots, X_n 的联合分布列为

$$\Pr(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) = \prod_{i=1}^n \Pr(X_i = x_i).$$

9.2 常用统计量

为研究样本的特性, 我们引入统计量:

定义 9.2 设 X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, $g(X_1, X_2, \dots, X_n)$ 是关于 X_1, X_2, \dots, X_n 的一个连续、且不含任意参数的函数, 称 $g(X_1, X_2, \dots, X_n)$ 是一个 **统计量**.

由于 X_1, X_2, \dots, X_n 是随机变量, 因此统计量 $g(X_1, X_2, \dots, X_n)$ 是一个随机变量. 而 $g(x_1, x_2, \dots, x_n)$ 为 $g(X_1, X_2, \dots, X_n)$ 的一次观察值. 下面研究一些常用统计量.

假设 X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, 定义 **样本均值** 为

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

根据样本的独立同分布性质有

引理 9.1 设总体 X 的期望为 $E[X] = \mu$, 方差 $\text{Var}(X) = \sigma^2$, 则有

$$E[\bar{X}] = \mu, \quad \text{Var}(\bar{X}) = \sigma^2/n, \quad \bar{X} \xrightarrow{d} \mathcal{N}(\mu, \sigma^2/n).$$

假设 X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, 定义 **样本方差** 为

$$S_0^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2.$$

引理 9.2 设总体 X 的期望为 $E[X] = \mu$, 方差 $\text{Var}(X) = \sigma^2$, 则有

$$E[S_0^2] = \frac{n-1}{n} \sigma^2.$$

证明 根据 $E[X_i^2] = \sigma^2 + \mu^2$ 有

$$E(\bar{X}^2) = E \left[\left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2 \right] = \frac{1}{n^2} E \left[\left(\sum_{i=1}^n X_i \right)^2 \right] = \frac{1}{n^2} E \left[\sum_{i=1}^n X_i^2 + \sum_{i \neq j} X_i X_j \right] = \frac{\sigma^2}{n} + \mu^2,$$

于是有

$$E(S_0^2) = E(X_i^2) - E(\bar{X}^2) = \sigma^2 + \mu^2 - \frac{\sigma^2}{n} - \mu^2 = \frac{n-1}{n}\sigma^2.$$

由此可知样本方差 S_0^2 与总体方差 σ^2 之间存在偏差.

进一步定义 **样本标准差** 为:

$$S_0 = \sqrt{S_0^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

定义 **修正后的样本方差** 为:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad \text{即} \quad S^2 = \frac{n}{n-1} S_0^2,$$

引理 9.3 设总体 X 的期望为 $E[X] = \mu$, 方差 $\text{Var}(X) = \sigma^2$, 则有

$$E[S^2] = \sigma^2.$$

证明 根据期望的性质有

$$E[S^2] = E\left[\frac{n}{n-1} S_0^2\right] = \frac{n}{n-1} E[S_0^2] = \sigma^2.$$

假设 X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, 定义 **样本 k 阶原点矩** 为:

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, \dots.$$

定义 **样本 k 阶中心矩** 为:

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, \quad k = 1, 2, \dots.$$

例 9.1 设总体 $X \sim \mathcal{N}(20, 3)$, 从总体中抽取两独立样本, 容量分别为 10 和 15. 求这两个样本均值之差的绝对值大于 0.3 的概率.

解 设 X_1, X_2, \dots, X_{10} 和 $X'_1, X'_2, \dots, X'_{15}$ 分别为来自总体 $X \sim \mathcal{N}(20, 3)$ 的两个独立样本. 根据正态分布的性质有

$$\bar{X}_1 = \frac{1}{10} \sum_{i=1}^{10} X_i \sim \mathcal{N}(20, 3/10), \quad \bar{X}_2 = \frac{1}{15} \sum_{i=1}^{15} X'_i \sim \mathcal{N}(20, 1/5).$$

进一步根据正态分布的性质有 $\bar{X}_1 - \bar{X}_2 \sim \mathcal{N}(0, 1/2)$, 于是可得

$$\Pr(|\bar{X}_1 - \bar{X}_2| > 0.3) = 2 - 2\Phi(0.3/\sqrt{1/2}).$$

假设 X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, 定义 **最小次序统计量** 和 **最大次序统计量** 分别为:

$$X_{(1)} = \min\{X_1, X_2, \dots, X_n\} \quad \text{和} \quad X_{(n)} = \max\{X_1, X_2, \dots, X_n\},$$

以及定义 **样本极差** 为

$$R_n = X_{(n)} - X_{(1)}.$$

设总体 X 的分布函数为 $F(x)$, 则有

$$F_{X_{(1)}}(x) = \Pr(X_{(1)} \leq x) = 1 - \Pr(X_{(1)} > x) = 1 - (1 - F(x))^n, \quad F_{X_{(n)}}(x) = F^n(x).$$

定理 9.1 设总体 X 的密度函数为 $f(x)$, 分布函数为 $F(x)$, X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, 则第 k 次序统计量 $X_{(k)}$ 的分布函数和密度函数分别为

$$\begin{aligned} F_k(x) &= \sum_{r=k}^n \binom{n}{r} [F(x)]^r [1 - F(x)]^{n-r} \\ f_k(x) &= \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1 - F(x)]^{n-k} f(x). \end{aligned}$$

证明 根据题意有第 k 次序统计量 $X_{(k)}$ 的分布函数为

$$\begin{aligned} F_k(x) &= \Pr[X_{(k)} \leq x] = \Pr[X_1, X_2, \dots, X_n \text{ 中至少有 } k \text{ 个随机变量 } \leq x] \\ &= \sum_{r=k}^n \Pr[X_1, X_2, \dots, X_n \text{ 中恰有 } r \text{ 个随机变量 } \leq x, n-r \text{ 个随机变量 } > x] \\ &= \sum_{r=k}^n \binom{n}{r} [F(x)]^r [1 - F(x)]^{n-r}. \end{aligned}$$

利用恒等式

$$\sum_{r=k}^n \binom{n}{r} p^r (1-p)^{n-r} = \frac{n!}{(k-1)!(n-k)!} \int_0^p t^{k-1} (1-t)^{n-k} dt \quad (r \in [n], p \in [0, 1])$$

由此可知

$$F_k(x) = \frac{n!}{(k-1)!(n-k)!} \int_0^{F(x)} t^{k-1} (1-t)^{n-k} dt,$$

根据积分函数求导完成证明.

9.3 Beta 分布、 Γ 分布、Dirichlet 分布

首先介绍两积分函数.

定义 9.3 (Beta-函数) 对任意给定 $\alpha_1 > 0$ 和 $\alpha_2 > 0$, 定义 Beta 函数为

$$\text{Beta}(\alpha_1, \alpha_2) = \int_0^1 x^{\alpha_1-1} (1-x)^{\alpha_2-1} dx,$$

有些书简记为 $B(\alpha_1, \alpha_2)$, 被称为第一类欧拉积分函数.

根据数学分析可知 $\text{Beta}(\alpha_1, \alpha_2)$ 在定义域 $(0, +\infty) \times (0, +\infty)$ 连续. 利用变量替换 $t = 1 - x$, 根据定义有

$$\begin{aligned} \text{Beta}(\alpha_1, \alpha_2) &= \int_0^1 t^{\alpha_1-1} (1-t)^{\alpha_2-1} dt = \int_1^0 (1-x)^{\alpha_1-1} x^{\alpha_2-1} d(1-x) \\ &= \int_0^1 x^{\alpha_2-1} (1-x)^{\alpha_1-1} dx = \text{Beta}(\alpha_2, \alpha_1), \end{aligned}$$

由此可知 Beta 函数的对称性: $\text{Beta}(\alpha_1, \alpha_2) = \text{Beta}(\alpha_2, \alpha_1)$.

定义 9.4 (Γ -函数) 对任意给定 $\alpha > 0$, 定义 Γ -函数为

$$\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx,$$

又被称为第二类欧拉积分函数.

性质 9.1 对 Γ -函数, 有 $\Gamma(1) = 1$ 和 $\Gamma(1/2) = \sqrt{\pi}$, 以及对 $\alpha > 1$ 有 $\Gamma(\alpha) = (\alpha - 1)\Gamma(\alpha - 1)$.

证明 根据定义有

$$\Gamma(1) = \int_0^{+\infty} e^{-x} dx = 1.$$

利用变量替换 $x = t^{1/2}$ 有

$$\Gamma(1/2) = \int_0^{+\infty} t^{-\frac{1}{2}} e^{-t} dt = \int_0^{+\infty} x^{-1} e^{-x^2} dx^2 = 2 \int_0^{+\infty} e^{-x^2} dx = \int_{-\infty}^{+\infty} e^{-x^2} dx = \sqrt{\pi}.$$

进一步有

$$\Gamma(\alpha) = - \int_0^\infty x^{\alpha-1} de^{-x} = -[x^{\alpha-1} e^{-x}]_0^{+\infty} + (\alpha - 1) \int_0^{+\infty} x^{\alpha-2} e^{-x} dx = (\alpha - 1)\Gamma(\alpha - 1)$$

对任意正整数 n , 根据上面的性质有

$$\Gamma(n) = (n - 1)!$$

关于 Beta 函数和 Γ -函数, 有如下关系:

定理 9.2 对任意给定 $\alpha_1 > 0$ 和 $\alpha_2 > 0$, 有

$$\text{Beta}(\alpha_1, \alpha_2) = \frac{\Gamma(\alpha_1)\Gamma(\alpha_2)}{\Gamma(\alpha_1 + \alpha_2)}.$$

证明 根据 Γ -函数的定义有

$$\Gamma(\alpha_1)\Gamma(\alpha_2) = \int_0^{+\infty} t^{\alpha_1-1} e^{-t} dt \int_0^{+\infty} s^{\alpha_2-1} e^{-s} ds = \int_0^{+\infty} \int_0^{+\infty} e^{-(t+s)} t^{\alpha_1-1} s^{\alpha_2-1} dt ds.$$

引入变量替换 $x = t + s$ 和 $y = t/(t + s)$, 反解可得 $t = xy$ 和 $s = x - xy$, 计算雅可比行列式有

$$\begin{vmatrix} \frac{\partial t}{\partial x} & \frac{\partial t}{\partial y} \\ \frac{\partial s}{\partial x} & \frac{\partial s}{\partial y} \end{vmatrix} = \begin{vmatrix} y & x \\ 1-y & -x \end{vmatrix} = -x.$$

同时有 $x \in (0, +\infty)$ 和 $y \in (0, 1)$ 成立, 由此可得

$$\begin{aligned} \Gamma(\alpha_1)\Gamma(\alpha_2) &= \int_0^1 \int_0^{+\infty} e^{-x} x^{\alpha_1-1} y^{\alpha_1-1} x^{\alpha_2-1} (1-y)^{\alpha_2-1} |x| dx dy \\ &= \int_0^1 \int_0^{+\infty} e^{-x} x^{\alpha_1+\alpha_2-1} y^{\alpha_1-1} (1-y)^{\alpha_2-1} dx dy \\ &= \int_0^{+\infty} e^{-x} x^{\alpha_1+\alpha_2-1} dx \int_0^1 y^{\alpha_1-1} (1-y)^{\alpha_2-1} dy \\ &= \Gamma(\alpha_1 + \alpha_2) \text{Beta}(\alpha_1, \alpha_2) \end{aligned}$$

定理得证.

根据上述定理可知

推论 9.1 对任意 $\alpha_1 > 1$ 和 $\alpha_2 > 0$, 有

$$\text{Beta}(\alpha_1, \alpha_2) = \frac{\alpha_1 - 1}{\alpha_1 + \alpha_2 - 1} \text{Beta}(\alpha_1 - 1, \alpha_2).$$

证明 根据前面的定理有

$$\text{Beta}(\alpha_1, \alpha_2) = \frac{\Gamma(\alpha_1)\Gamma(\alpha_2)}{\Gamma(\alpha_1 + \alpha_2)} = \frac{(\alpha_1 - 1)\Gamma(\alpha_1 - 1)\Gamma(\alpha_2)}{(\alpha_1 + \alpha_2 - 1)\Gamma(\alpha_1 + \alpha_2 - 1)} = \frac{\alpha_1 - 1}{\alpha_1 + \alpha_2 - 1} \text{Beta}(\alpha_1 - 1, \alpha_2).$$

定义 9.5 对任意 $\alpha_1, \alpha_2, \dots, \alpha_k > 0$, 定义多维 Beta 函数为

$$\text{Beta}(\alpha_1, \alpha_2, \dots, \alpha_k) = \frac{\Gamma(\alpha_1)\Gamma(\alpha_2) \cdots \Gamma(\alpha_k)}{\Gamma(\alpha_1 + \alpha_2 + \cdots + \alpha_k)}.$$

下面介绍三种分布:

定义 9.6 (Beta 分布) 给定 $\alpha_1 > 0$ 和 $\alpha_2 > 0$, 若随机变量 X 的概率密度为

$$f(x) = \begin{cases} \frac{x^{\alpha_1-1}(1-x)^{\alpha_2-1}}{B(\alpha_1, \alpha_2)} & x \in (0, 1) \\ 0 & \text{其它.} \end{cases}$$

称 X 服从参数为 α_1 和 α_2 的 Beta 分布, 记 $X \sim B(\alpha_1, \alpha_2)$.

定理 9.3 若随机变量 $X \sim B(\alpha_1, \alpha_2)$, 则有

$$E[X] = \frac{\alpha_1}{\alpha_1 + \alpha_2} \quad \text{和} \quad \text{Var}(X) = \frac{\alpha_1 \alpha_2}{(\alpha_1 + \alpha_2)^2 (\alpha_1 + \alpha_2 + 1)}.$$

证明 根据期望的定义有

$$\begin{aligned} E[X] &= \frac{1}{B(\alpha_1, \alpha_2)} \int_0^1 x \cdot x^{\alpha_1-1}(1-x)^{\alpha_2-1} dx = \frac{B(\alpha_1+1, \alpha_2)}{B(\alpha_1, \alpha_2)} = \frac{\alpha_1}{\alpha_1 + \alpha_2}, \\ E[X^2] &= \frac{1}{B(\alpha_1, \alpha_2)} \int_0^1 x^{\alpha_1+1}(1-x)^{\alpha_2-1} dx = \frac{B(\alpha_1+2, \alpha_2)}{B(\alpha_1, \alpha_2)} = \frac{\alpha_1+1}{\alpha_1 + \alpha_2 + 1} \frac{\alpha_1}{\alpha_1 + \alpha_2}, \end{aligned}$$

由此可得

$$\text{Var}(X) = E[X^2] - E[X]^2 = \frac{\alpha_1(1+\alpha_1)}{(\alpha_1 + \alpha_2)(\alpha_1 + \alpha_2 + 1)} - \left(\frac{\alpha_1}{\alpha_1 + \alpha_2}\right)^2 = \frac{\alpha_1 \alpha_2}{(\alpha_1 + \alpha_2)^2 (\alpha_1 + \alpha_2 + 1)}.$$

例 9.2 设独立同分布随机变量 X_1, X_2, \dots, X_n 服从均匀分布 $\mathcal{U}(0, 1)$, 记 $X_{(k)}$ 为其顺序统计量, 则

$$X_{(k)} \sim B(k, n-k+1).$$

证明 若随机变量 $X_i \sim U(0, 1)$ ($i \in [n]$), 则当 $x \in (0, 1)$ 时其分布函数 $F(x) = x$. 由此可得到第 k 个统计量 $X_{(k)}$ 的概率密度函数

$$\begin{aligned} f(x) &= \frac{n!}{(k-1)!(n-k)!} (F(x))^{k-1} (1-F(x))^{n-k} = \frac{n!}{(k-1)!(n-k)!} x^{k-1} (1-x)^{n-k} \\ &= \frac{1}{B(k, n-k+1)} x^{k-1} (1-x)^{n-k}. \end{aligned}$$

下面定义 Γ 分布:

定义 9.7 如果随机变量 X 的概率密度

$$f(x) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

其中 $\alpha > 0$ 和 $\lambda > 0$, 则称随机变量 X 服从参数为 α 和 λ 的 Γ 分布, 记为 $X \sim \Gamma(\alpha, \lambda)$.

定理 9.4 若随机变量 $X \sim \Gamma(\alpha, \lambda)$, 则有 $E(X) = \alpha/\lambda$ 和 $\text{Var}(X) = \alpha/\lambda^2$.

证明 根据期望的定义有

$$E[X] = \int_0^\infty \frac{\lambda^\alpha}{\Gamma(\alpha)} x^\alpha e^{-\lambda x} dx = \frac{\Gamma(\alpha+1)}{\lambda \Gamma(\alpha)} \int_0^\infty \frac{\lambda^{\alpha+1}}{\Gamma(\alpha+1)} x^\alpha e^{-\lambda x} dx = \alpha/\lambda.$$

以及

$$E[X^2] = \int_0^\infty \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha+1} e^{-\lambda x} dx = \frac{\Gamma(\alpha+2)}{\lambda^2 \Gamma(\alpha)} \int_0^\infty \frac{\lambda^{\alpha+2}}{\Gamma(\alpha+2)} x^{\alpha+1} e^{-\lambda x} dx = \alpha(\alpha+1)/\lambda^2,$$

由此可得

$$\text{Var}(X) = E[X^2] - (E[X])^2 = \alpha(\alpha+1)/\lambda^2 - \alpha^2/\lambda^2 = \alpha/\lambda^2.$$

我们有 Γ 分布的可加性:

定理 9.5 若随机变量 $X \sim \Gamma(\alpha_1, \lambda)$ 和 $Y \sim \Gamma(\alpha_2, \lambda)$, 且 X 与 Y 相互独立, 则 $X + Y \sim \Gamma(\alpha_1 + \alpha_2, \lambda)$.

证明 设随机变量 $Z = X + Y$, 根据独立同分布随机变量和函数的分布有随机变量 Z 的概率密度为

$$\begin{aligned} f_Z(z) &= \int_{-\infty}^\infty f_X(x) f_Y(z-x) dx = \int_0^z \frac{\lambda^{\alpha_1}}{\Gamma(\alpha_1)} x^{\alpha_1-1} e^{-\lambda x} \frac{\lambda^{\alpha_2}}{\Gamma(\alpha_2)} (z-x)^{\alpha_2-1} e^{-\lambda(z-x)} dx \\ &= \frac{\lambda^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} e^{-\lambda z} \int_0^z x^{\alpha_1-1} (z-x)^{\alpha_2-1} dx \end{aligned}$$

令变量替换 $x = zt$ 有

$$\int_0^z x^{\alpha_1-1} (z-x)^{\alpha_2-1} dx = z^{\alpha_1+\alpha_2-1} \int_0^1 t^{\alpha_1-1} (1-t)^{\alpha_2-1} dt = z^{\alpha_1+\alpha_2-1} \mathcal{B}(\alpha_1, \alpha_2)$$

在利用 Beta 函数的性质

$$\mathcal{B}(\alpha_1, \alpha_2) = \int_0^1 t^{\alpha_1-1} (1-t)^{\alpha_2-1} dt = \frac{\Gamma(\alpha_1)\Gamma(\alpha_2)}{\Gamma(\alpha_1 + \alpha_2)}$$

代入完成证明.

特别地, 若随机变量 $X \sim \Gamma(1/2, 1/2)$, 则其密度函数为

$$f(x) = \begin{cases} \frac{1}{\sqrt{2\pi}} x^{-\frac{1}{2}} e^{-\frac{1}{2}x} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

例 9.3 若随机变量 $X \sim \mathcal{N}(0, 1)$, 则有 $X^2 \sim \Gamma(1/2, 1/2)$.

解 首先求解随机变量函数 $Y = X^2$ 的分布函数. 当 $y \leq 0$ 时有 $F_Y(y) = 0$; 当 $y > 0$ 时有

$$F_Y(y) = \Pr(X^2 \leq y) = \Pr(-\sqrt{y} \leq X \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx,$$

由此得到概率密度为 $f_Y(y) = \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{y}} e^{-\frac{y}{2}}$. 从而得到 $X^2 \sim \Gamma(1/2, 1/2)$.

下面介绍 Dirichlet 分布:

定义 9.8 给定 $\alpha_1, \alpha_2, \dots, \alpha_k \in (0, +\infty)$, 若多元随机向量 $X = (X_1, X_2, \dots, X_k)$ 的密度函数为

$$f(x_1, x_2, \dots, x_k) = \begin{cases} \frac{x_1^{\alpha_1-1} x_2^{\alpha_2-1} \cdots x_k^{\alpha_k-1}}{\text{Beta}(\alpha_1, \alpha_2, \dots, \alpha_k)} & \sum_{i=1}^k x_i = 1, x_i > 0 \ (i \in [k]), \\ 0 & \text{其它} \end{cases}$$

则称 X 服从参数为 $\alpha_1, \alpha_2, \dots, \alpha_k$ 的 Dirichlet 分布, 记 $X \sim \text{Dir}(\alpha_1, \alpha_2, \dots, \alpha_k)$.

Dirichlet 分布是 Beta 分布的一种推广, 当 $k = 2$ 时 Dirichlet 分布退化为 Beta 分布.

定理 9.6 若随机向量 $X = (X_1, X_2, \dots, X_k) \sim \text{Dir}(\alpha_1, \alpha_2, \dots, \alpha_k)$, 设 $\tilde{\alpha} = \alpha_1 + \alpha_2 + \dots + \alpha_k$ 和 $\tilde{\alpha}_i = \alpha_i / \tilde{\alpha}$, 则

$$E[X_i] = \tilde{\alpha}_i \quad \text{和} \quad \text{Cov}(X_i, X_j) = \begin{cases} \frac{\tilde{\alpha}_i(1-\tilde{\alpha}_i)}{\tilde{\alpha}+1} & i = j, \\ -\frac{\tilde{\alpha}_i \tilde{\alpha}_j}{\tilde{\alpha}+1} & i \neq j. \end{cases}$$

证明 根据期望的定义有

$$\begin{aligned} E[X_i] &= \frac{\int \int_{\sum_i x_i = 1, x_i \geq 0} x_1^{\alpha_1-1} x_2^{\alpha_2-1} \cdots x_k^{\alpha_k-1} \cdot x_i dx_1 \cdots dx_k}{\text{Beta}(\alpha_1, \alpha_2, \dots, \alpha_k)} \\ &= \frac{\text{Beta}(\alpha_1, \dots, \alpha_i + 1, \dots, \alpha_k)}{\text{Beta}(\alpha_1, \dots, \alpha_i, \dots, \alpha_k)} = \frac{\alpha_i}{\alpha_1 + \alpha_2 + \dots + \alpha_k} = \tilde{\alpha}_i. \end{aligned}$$

若 $i = j$, 则有

$$\text{Cov}(X_i, X_i) = E[X_i^2] - (E[X_i])^2 = \frac{\text{Beta}(\alpha_1, \dots, \alpha_i + 2, \dots, \alpha_k)}{\text{Beta}(\alpha_1, \dots, \alpha_i, \dots, \alpha_k)} - (\tilde{\alpha}_i)^2 = \frac{\tilde{\alpha}_i(1-\tilde{\alpha}_i)}{\tilde{\alpha}+1}.$$

若 $i \neq j$, 则有

$$\begin{aligned} \text{Cov}(X_i, X_j) &= E[X_i X_j] - E[X_i] E[X_j] = \frac{\text{Beta}(\alpha_1, \dots, \alpha_i + 1, \dots, \alpha_j + 1, \dots, \alpha_k)}{\text{Beta}(\alpha_1, \dots, \alpha_i, \dots, \alpha_j, \dots, \alpha_k)} - \tilde{\alpha}_i \tilde{\alpha}_j \\ &= \frac{\alpha_i \alpha_j}{\tilde{\alpha}(\tilde{\alpha}+1)} - \tilde{\alpha}_i \tilde{\alpha}_j = -\frac{\tilde{\alpha}_i \tilde{\alpha}_j}{\tilde{\alpha}+1}. \end{aligned}$$

9.4 正态总体抽样分布定理

9.4.1 χ^2 分布

定义 9.9 若 X_1, X_2, \dots, X_n 是来自总体 $X \sim \mathcal{N}(0, 1)$ 的一个样本, 称 $Y = X_1^2 + X_2^2 + \dots + X_n^2$ 为服从自由度为 n 的 χ^2 分布, 记 $Y \sim \chi^2(n)$.

根据 $X_1^2 \sim \Gamma(1/2, 1/2)$ 和 Γ 函数的可加性可得 $Y \sim \Gamma(n/2, 1/2)$. 于是有随机变量 Y 的概率密度为

$$f_Y(y) = \begin{cases} \frac{(\frac{1}{2})^{\frac{n}{2}}}{\Gamma(n/2)} y^{\frac{n}{2}-1} e^{-\frac{y}{2}} & y > 0 \\ 0 & y \leq 0 \end{cases}$$

下面研究 χ^2 分布的性质:

定理 9.7 若随机变量 $X \sim \chi^2(n)$, 则 $E(X) = n$ 和 $\text{Var}(X) = 2n$; 若随机变量 $X \sim \chi^2(m)$ 和 $Y \sim \chi^2(n)$ 相互独立, 则 $X + Y \sim \chi^2(m + n)$;

证明 若随机变量 $X \sim \chi^2(n)$, 则有 $X = X_1^2 + X_2^2 + \dots + X_n^2$, 其中 X_1, X_2, \dots, X_n 是总体为 $X' \sim \mathcal{N}(0, 1)$ 的一个样本. 我们有

$$\begin{aligned} E[X] &= E[X_1^2 + X_2^2 + \dots + X_n^2] = nE[X_1^2] = n, \\ \text{Var}(X) &= n\text{Var}(X_1^2) = n[E(X_1^4) - (E(X_1^2))^2] = n(E(X_1^4) - 1). \end{aligned}$$

计算

$$E(X_1^4) = \int_{-\infty}^{+\infty} \frac{x^4}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = - \int_{-\infty}^{+\infty} \frac{x^3}{\sqrt{2\pi}} de^{-\frac{x^2}{2}} = 3 \int_{-\infty}^{+\infty} \frac{x^2}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = 3$$

可得 $\text{Var}(X) = 2n$.

若随机变量 $X \sim \mathcal{N}(0, 1)$, 则

$$E(X^k) = \begin{cases} (k-1)!! & k \text{ 为偶数} \\ 0 & k \text{ 为奇数} \end{cases}$$

其中 $(2k)!! = 2k \cdot (2k-2) \cdots 2$ 和 $(2k+1)!! = (2k+1) \cdot (2k-1) \cdots 1$.

例 9.4 设 X_1, X_2, X_3, X_4 是来自于总体 $\mathcal{N}(0, 4)$ 的样本, 以及 $Y = a(X_1 - 2X_2)^2 + b(3X_3 - 4X_4)^2$. 求 a, b 取何值时, Y 服从 χ^2 分布, 并求其自由度.

解 根据正态分布的性质有 $X_1 - 2X_2 \sim \mathcal{N}(0, 20)$ 和 $3X_3 - 4X_4 \sim \mathcal{N}(0, 100)$, 因此

$$\frac{X_1 - 2X_2}{2\sqrt{5}} \sim \mathcal{N}(0, 1), \quad \frac{3X_3 - 4X_4}{10} \sim \mathcal{N}(0, 1),$$

所以当 $a = 1/20, b = 1/100$ 时有 $Y \sim \chi^2(2)$ 成立.

分布可加性:

- 如果 $X \sim \mathcal{N}(\mu_1, a_1^2)$ 和 $Y \sim \mathcal{N}(\mu_2, a_2^2)$, 且 X 与 Y 独立, 那么 $X \pm Y \sim \mathcal{N}(\mu_1 \pm \mu_2, a_1^2 + a_2^2)$;
- 如果 $X \sim B(n_1, p)$ 和 $Y \sim B(n_2, p)$, 且 X 与 Y 独立, 那么 $X + Y \sim B(n_1 + n_2, p)$;
- 如果 $X \sim P(\lambda_1)$ 和 $Y \sim P(\lambda_2)$, 且 X 与 Y 独立, 那么 $X + Y \sim P(\lambda_1 + \lambda_2)$;
- 如果 $X \sim \Gamma(\alpha_1, \lambda)$ 和 $Y \sim \Gamma(\alpha_2, \lambda)$, 且 X 与 Y 独立, 那么 $X + Y \sim \Gamma(\alpha_1 + \alpha_2, \lambda)$.
- 如果 $X \sim \chi(m)$ 和 $Y \sim \chi(n)$, 且 X 与 Y 独立, 那么 $X + Y \sim \chi(m + n)$.

9.4.2 t 分布 (student distribution)

定义 9.10 随机变量 $X \sim \mathcal{N}(0, 1)$ 和 $Y \sim \chi^2(n)$ 相互独立, 则随机变量

$$T = \frac{X}{\sqrt{Y/n}}$$

服从自由度为 n 的 t -分布, 记 $T \sim t(n)$.

随机变量 $T \sim t(n)$ 的概率密度为

$$f(x) = \frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})\sqrt{n\pi}} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}} \quad x \in (-\infty, +\infty).$$

由此可知 t -分布的密度函数 $f(x)$ 是偶函数. 当 $n > 1$ 为偶数时有

$$\frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})\sqrt{n\pi}} = \frac{(n-1)(n-3)\cdots 5 \cdot 3}{2\sqrt{n}(n-2)(n-4)\cdots 4 \cdot 2};$$

当 $n > 1$ 为奇数时有

$$\frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})\sqrt{n\pi}} = \frac{(n-1)(n-3)\cdots 4 \cdot 2}{\pi\sqrt{n}(n-2)(n-4)\cdots 5 \cdot 3}.$$

当 $n \rightarrow \infty$ 时, 随机变量 $T \sim t(n)$ 的概率密度

$$f(x) \rightarrow \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}.$$

因此当 n 足够大时, $f(x)$ 可被近似为 $\mathcal{N}(0, 1)$ 的密度函数.

9.4.3 F 分布

定义 9.11 设随机变量 $X \sim \chi^2(m)$ 和 $Y \sim \chi^2(n)$ 相互独立, 称随机变量

$$F = \frac{X/m}{Y/n}$$

服从自由度为 (m, n) 的 F -分布, 记 $F \sim F(m, n)$.

随机变量 $F \sim F(m, n)$ 的概率密度为

$$f(x) = \begin{cases} \frac{\Gamma(\frac{m+n}{2})(\frac{m}{n})^{\frac{m}{2}}x^{\frac{m}{2}-1}}{\Gamma(\frac{m}{2})\Gamma(\frac{n}{2})(1+\frac{mx}{n})^{\frac{m+n}{2}}} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

若随机变量 $F \sim F(m, n)$, 则 $\frac{1}{F} = F(n, m)$.

课题练习:

- 独立同分布随机变量 X_1, X_2, \dots, X_n 满足 $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$, 求 $\sum_{i=1}^n (X_i - \mu_i)^2 / \sigma_i^2$ 的分布.
- 设 X_1, X_2, \dots, X_9 和 Y_1, Y_2, \dots, Y_9 是分别来自总体 $\mathcal{N}(0, 9)$ 的两个独立样本, 求 $(X_1 + X_2 + \dots + X_9) / \sqrt{Y_1^2 + Y_2^2 + \dots + Y_9^2}$ 的分布.
- 设 X_1, X_2, \dots, X_{2n} 来自总体 $\mathcal{N}(0, \sigma^2)$ 的样本, 求 $(X_1^2 + X_3^2 + \dots + X_{2n-1}^2) / (X_2^2 + X_4^2 + \dots + X_{2n}^2)$ 的分布.

9.4.4 正态分布的抽样分布定理

定理 9.8 设 X_1, X_2, \dots, X_n 是来自总体 $\mathcal{N}(\mu, \sigma^2)$ 的样本, 则有

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right), \quad \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1).$$

定理 9.9 设 X_1, X_2, \dots, X_n 是来自总体 $\mathcal{N}(\mu, \sigma^2)$ 的样本, 其样本均值和修正样本方差分别为

$$\bar{X} = \sum_{i=1}^n X_i/n \quad \text{和} \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

则有 \bar{X} 和 S^2 相互独立, 且

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1).$$

此定理证明参考书的附件.

定理 9.10 设 X_1, X_2, \dots, X_n 是来自总体 $\mathcal{N}(\mu, \sigma^2)$ 的样本, 其样本均值和修正样本方差分别为

$$\bar{X} = \sum_{i=1}^n X_i/n \quad \text{和} \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

则有

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

证明 根据前面两个定理可知 $(\bar{X} - \mu)/\sigma\sqrt{n} \sim \mathcal{N}(0, 1)$ 和 $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$, 于是有

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sqrt{\frac{(n-1)S^2}{\sigma^2(n-1)}} \sim t(n-1).$$

定理 9.11 设 X_1, X_2, \dots, X_m 和 Y_1, Y_2, \dots, Y_n 分别来自总体 $\mathcal{N}(\mu_X, \sigma^2)$ 和 $\mathcal{N}(\mu_Y, \sigma^2)$ 的两个独立样本, 令其样本均值分别 \bar{X} 和 \bar{Y} , 修正样本方差分别为 S_X^2 和 S_Y^2 , 则

$$\frac{\bar{X} - \bar{Y} - (\mu_X - \mu_Y)}{\sqrt{\frac{(m-1)S_X^2 + (n-1)S_Y^2}{m+n-2}} \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t(m+n-2).$$

证明 根据正太分布的性质有 $\bar{X} \sim \mathcal{N}(\mu_X, \sigma^2/m)$ 和 $\bar{Y} \sim \mathcal{N}(\mu_Y, \sigma^2/n)$, 以及

$$\bar{X} - \bar{Y} \sim \mathcal{N}\left(\mu_X - \mu_Y, \left(\frac{1}{m} + \frac{1}{n}\right)\sigma^2\right),$$

进一步有

$$\frac{\bar{X} - \bar{Y} - (\mu_X - \mu_Y)}{\sigma\sqrt{\frac{1}{m} + \frac{1}{n}}} \sim \mathcal{N}(0, 1).$$

根据定理 9.9 有 $\frac{(m-1)S_X^2}{\sigma^2} \sim \chi^2(m-1)$ 和 $\frac{(n-1)S_Y^2}{\sigma^2} \sim \chi^2(n-1)$, 由此得到

$$\frac{(m-1)S_X^2 + (n-1)S_Y^2}{\sigma^2} \sim \chi^2(m+n-2).$$

从而完成证明.

定理 9.12 设 X_1, X_2, \dots, X_m 和 Y_1, Y_2, \dots, Y_n 分别来自总体 $\mathcal{N}(\mu_X, \sigma_X^2)$ 和 $\mathcal{N}(\mu_Y, \sigma_Y^2)$ 的两个独立样本, 令其修正样本方差分别为 S_X^2 和 S_Y^2 , 则有

$$\frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \sim F(m-1, n-1).$$

证明 根据定理 9.9 有 $\frac{(m-1)S_X^2}{\sigma_X^2} \sim \chi^2(m-1)$ 和 $\frac{(n-1)S_Y^2}{\sigma_Y^2} \sim \chi^2(n-1)$, 由此得到

$$\frac{\frac{(m-1)S_X^2}{\sigma_X^2}/(m-1)}{\frac{(n-1)S_Y^2}{\sigma_Y^2}/(n-1)} \sim F(m-1, n-1).$$

课堂习题:

- 若随机变量 $X \sim t(n)$, 求 $Y = X^2$ 的分布.

- 设 X_1, X_2, \dots, X_5 是来自总体 $\mathcal{N}(0, 1)$ 的样本, 令 $Y = c_1(X_1 + X_3)^2 + c_2(X_2 + X_4 + X_5)^2$. 求常数 c_1, c_2 使 Y 服从 χ^2 分布.
- 设 X_1, X_2 是来自总体 $\mathcal{N}(0, \sigma^2)$ 的样本, 求 $\frac{(X_1+X_2)^2}{(X_1-X_2)^2}$ 的分布.

9.4.5 分位数(点)

定义 9.12 对给定 $\alpha \in (0, 1)$ 和随机变量 X , 称满足 $\Pr(X > \lambda_\alpha) = \alpha$ 的实数 λ_α 为上侧 α 分位数(点).

对正态分布 $X \sim \mathcal{N}(0, 1)$, 给定 $\alpha \in (0, 1)$, 满足 $\Pr(X > \mu_\alpha) = \int_{\mu_\alpha}^\infty f(x)dx = \alpha$ 的点 μ_α 称为正态分布上侧 α 分位点, 由对称性可知 $\mu_{1-\alpha} = -\mu_\alpha$.

对 $\chi^2(n)$ 分布 $X \sim \chi^2(n)$, 给定 $\alpha \in (0, 1)$, 满足 $\Pr(X \geq \chi_\alpha^2(n)) = \alpha$ 的点 $\chi_\alpha^2(n)$ 称为 $\chi^2(n)$ 分布上侧 α 分位点. 当 $n \rightarrow \infty$ 时有 $\chi_\alpha^2(n) \approx \frac{1}{2}(\mu_\alpha + \sqrt{2n-1})^2$, 其中 μ_α 表示正态分布上侧 α 分位点.

对 t -分布 $X \sim t(n)$, 给定 $\alpha \in (0, 1)$, 满足 $\Pr(X > t_\alpha(n)) = \alpha$ 的点 $t_\alpha(n)$ 称为 $t(n)$ -分布上侧 α 分位点. 由对称性可知 $t_{(1-\alpha)}(n) = -t_\alpha(n)$.

对 F -分布 $X \sim F(m, n)$, 给定 $\alpha \in (0, 1)$, 满足 $\Pr[X > F_\alpha(m, n)] = \alpha$ 的点 $F_\alpha(m, n)$ 称为 $F(m, n)$ 分布上侧 α 分位点.

对于 F -分布, 有如下性质:

引理 9.4 对 F 分布的分位点有

$$F_{(1-\alpha)}(m, n) = \frac{1}{F_\alpha(n, m)}.$$

证明 设 $X \sim F(m, n)$, 根据定义有

$$1 - \alpha = \Pr(X > F_{1-\alpha}(m, n)) = \Pr\left(\frac{1}{X} < \frac{1}{F_{1-\alpha}(m, n)}\right) = 1 - \Pr\left(\frac{1}{X} \geq \frac{1}{F_{1-\alpha}(m, n)}\right).$$

再根据 $1/X \sim F(n, m)$, 结合上式有

$$\alpha = \Pr\left(\frac{1}{X} \geq \frac{1}{F_{1-\alpha}(m, n)}\right) = \Pr\left(\frac{1}{X} > \frac{1}{F_{1-\alpha}(m, n)}\right)$$

于是有 $F_\alpha(n, m) = 1/F_{1-\alpha}(m, n)$.

课堂习题:

- 设 X_1, X_2, \dots, X_{10} 是总体 $\mathcal{N}(\mu, 1/4)$ 的样本, i) 若 $\mu = 0$, 求 $\Pr(\sum_{i=1}^{10} X_i^2 \geq 4)$; ii) 若 μ 未知, 求 $\Pr(\sum_{i=1}^{10} (X_i - \bar{X})^2 \geq 2.85)$.
- 设 X_1, X_2, \dots, X_{25} 是总体 $\mathcal{N}(12, \sigma^2)$ 的样本, i) 若 $\sigma = 2$, 求 $\Pr(\sum_{i=1}^{25} X_i/25 \geq 12.5)$; ii) 若 σ 未知但知道修正样本方差为 $S^2 = 5.57$, 求 $\Pr(\sum_{i=1}^{25} X_i/25 \geq 12.5)$.

习题

9.1 设随机变量 X 的期望 $E[X] = \mu > 0$, 方差为 σ^2 , 证明对任意 $\epsilon > 0$ 有

$$P(X - \mu \leq -\epsilon) \leq \frac{\sigma^2}{\sigma^2 + \epsilon^2}.$$